

神经网络的模型与应用：期终考核答题报告

姓名：宋嘉硕 学号：25114020014

2026 年 7 月

目录

说明	2
1 第 2 题：Ordinary renewal process 的高阶统计量	2
1.1 一阶矩	2
1.2 下降阶乘矩	3
1.3 任意 n 阶普通矩	3
1.4 二阶矩和方差	3
1.5 数值验证	3
2 第 4 题：神经元群体编码与刺激方向估计	4
3 第 5 题：音频盲源分离	6
4 第 6 题：MNIST 分类中的 SGD 与近似自然梯度	8
5 第 7 题：强化学习求解迷宫最短路径	9
6 结论	11

说明

本文完成第 2、4、5、6、7 题。所有数值实验均可通过项目根目录下的 `run_all.py` 一次性复现。运行命令为：

```
python3 run_all.py
xelatex report.tex
xelatex report.tex
```

如只需快速检查第 2、4、5、7 题，可使用：

```
python3 run_all.py --skip-q6
```

1 第 2 题: Ordinary renewal process 的高阶统计量

设更新间隔为独立同分布随机变量

$$X_1, X_2, \dots \stackrel{\text{i.i.d.}}{\sim} F,$$

第 k 次更新时刻为

$$S_k = X_1 + \dots + X_k,$$

并定义截至时刻 t 的更新次数

$$N(t) = \max\{k : S_k \leq t\}.$$

记 $F^{*k}(t) = \mathbb{P}(S_k \leq t)$ 为 F 的 k 次卷积分布函数。

1.1 一阶矩

由于

$$\{N(t) \geq k\} \iff \{S_k \leq t\},$$

可写成

$$N(t) = \sum_{k=1}^{\infty} \mathbf{1}_{\{S_k \leq t\}}.$$

取期望得到更新函数

$$m(t) = \mathbb{E}[N(t)] = \sum_{k=1}^{\infty} F^{*k}(t).$$

1.2 下降阶乘矩

定义下降阶乘

$$(N(t))_r = N(t)(N(t) - 1) \cdots (N(t) - r + 1).$$

利用 $(N(t))_r = r! \binom{N(t)}{r}$, 并按照最后一个下标 $k_r = k$ 分类, 可得

$$\mathbb{E}[(N(t))_r] = r! \sum_{k=r}^{\infty} \binom{k-1}{r-1} F^{*k}(t).$$

1.3 任意 n 阶普通矩

利用第二类 Stirling 数 $S(n, r)$ 的恒等式

$$N(t)^n = \sum_{r=1}^n S(n, r) (N(t))_r,$$

得到

$$\mathbb{E}[N(t)^n] = \sum_{r=1}^n S(n, r) r! \sum_{k=r}^{\infty} \binom{k-1}{r-1} F^{*k}(t).$$

这就是更新计数 $N(t)$ 的任意阶矩表达式。

1.4 二阶矩和方差

当 $n = 2$ 时,

$$\mathbb{E}[N(t)^2] = \sum_{k=1}^{\infty} F^{*k}(t) + 2 \sum_{k=2}^{\infty} (k-1) F^{*k}(t),$$

因此

$$\text{Var}(N(t)) = \sum_{k=1}^{\infty} F^{*k}(t) + 2 \sum_{k=2}^{\infty} (k-1) F^{*k}(t) - \left(\sum_{k=1}^{\infty} F^{*k}(t) \right)^2.$$

1.5 数值验证

取指数更新间隔 $X_i \sim \text{Exp}(\lambda)$, 其中

$$\lambda = 1.7, \quad t = 3.0.$$

此时 $N(t) \sim \text{Poisson}(\lambda t)$, 理论均值与方差均为

$$\lambda t = 5.10000.$$

在 100000 次 Monte Carlo 模拟中, 得到

$$\widehat{\mathbb{E}[N(t)]} = 5.10613, \quad \widehat{\text{Var}(N(t))} = 5.11051.$$

模拟结果与理论值一致。




图 1: 指数更新间隔下, 更新计数分布与 Poisson 理论分布的比较。

2 第 4 题：神经元群体编码与刺激方向估计

题目给出的第 a 个神经元调谐函数为

$$f_a(s) = \exp \left[-\frac{(s - s_a)^2}{2\sigma_a^2} \right], \quad s \in [0, 180^\circ], \quad \sigma_a > 0,$$

其中 s_a 为第 a 个神经元的偏好方向, σ_a 为调谐宽度参数。

设在长度为 T 的观测窗口内, 第 a 个神经元记录到的脉冲数为 n_a 。由于各神经元相互独立, 且均服从 Poisson 过程,

$$n_a \sim \text{Poisson}(T f_a(s)).$$

联合似然为

$$p(\mathbf{n} | s) = \prod_{a=1}^N \frac{[T f_a(s)]^{n_a}}{n_a!} \exp[-T f_a(s)].$$

忽略与 s 无关的常数项, 对数似然为

$$\ell(s) = \sum_{a=1}^N [n_a \log f_a(s) - T f_a(s)].$$

因此采用网格搜索构造最大似然估计

$$\hat{s}_{\text{MLE}} = \arg \max_{s \in [0, 180^\circ]} \ell(s).$$

题目给出的贝叶斯损失为平方差，因此使用直接误差

$$e = \hat{s} - s, \quad \text{MSE} = \mathbb{E}[(\hat{s} - s)^2].$$

高斯调谐函数的导数为

$$f'_a(s) = -\frac{s - s_a}{\sigma_a^2} f_a(s).$$

对于独立 Poisson 神经元，Fisher 信息为

$$I(s) = T \sum_{a=1}^N \frac{[f'_a(s)]^2}{f_a(s)} = T \sum_{a=1}^N \frac{(s - s_a)^2}{\sigma_a^4} f_a(s).$$

无偏估计量满足 Cramér–Rao 下界

$$\text{Var}(\hat{s}) \geq \frac{1}{I(s)}.$$

一般情况下，该模型的有限样本 MVUB 估计不容易写成简单闭式表达式。本文使用 MLE 作为数值近似，并通过经验偏差与 Cramér–Rao 下界判断其是否接近有效无偏估计。

数值模拟中使用 $N = 60$ 个神经元，令偏好方向均匀分布于 $[0, 180^\circ]$ ，并设置

$$T = 20.0, \quad s_{\text{true}} = 72.0^\circ, \quad \sigma_a = 15.0^\circ.$$

在 1000 次独立模拟中，得到：

指标	数值
经验偏差	$-0.000511 \text{ rad} = -0.0292^\circ$
经验 MSE	0.000284 rad^2
经验 RMSE	0.9656°
Fisher 信息	3596.2368
Cramér–Rao 下界	0.000278 rad^2
MSE / CRLB	1.0213

表 1: 高斯调谐函数下的方向解码实验结果。

经验偏差接近于零，且经验 MSE 仅比理论下界高约 2.13%。因此，在当前参数下，MLE 近似无偏，并接近有效估计。




图 2: 1000 次独立模拟中的方向估计误差直方图。

3 第 5 题：音频盲源分离

使用 FastICA 对附件中的三路混合音频进行盲源分离，并以 PCA 作为基线。PCA 的目标是去除线性相关性，而 FastICA 进一步追求统计独立性。因此，仅比较相关系数是不充分的，还需要结合互信息、峰度和主观试听结果。

方法	平均绝对非对角相关系数	平均互信息	绝对峰度
FastICA	$3.002407951893188e - 15$	0.02441	[1.267364741.194604420.92883599]
PCA baseline	$3.837330453401076e - 16$	0.07586	[0.701396050.438528850.50141626]

表 2: FastICA 与 PCA 的盲源分离指标。

FastICA 的平均互信息比 PCA 低约 67.8%，说明输出分量更接近统计独立。试听结果如下：

- FastICA component 1：主要为背景声；
- FastICA component 2：主要为人声；
- FastICA component 3：主要为音乐；
- PCA component 1：人声与背景声仍然混合；
- PCA component 2：音乐与背景声仍然混合；

- PCA component 3: 主要为背景声。

因此，FastICA 比 PCA 更适合本实验中的盲源分离任务。由于附件未提供干净的源信号，无法严格计算 SDR 或 SIR，本文使用统计指标、波形图和试听结果进行评价。




图 3: FastICA 分离后的三路信号波形。




图 4: PCA 基线方法得到的三路信号波形。

4 第 6 题: MNIST 分类中的 SGD 与近似自然梯度

使用一个简单的多层感知机进行 MNIST 手写数字分类: 输入维数为 784, 隐藏层包含 128 个神经元并采用 $\tanh$ 激活函数, 输出层包含 10 个类别。

标准 SGD 更新为

$$\theta_{t+1} = \theta_t - \eta g_t.$$

完整自然梯度需要计算和求逆 Fisher 信息矩阵, 代价较高。本文使用对角经验 Fisher 预条件近似:

$$f_t = \beta f_{t-1} + (1 - \beta) g_t^2,$$

并采用

$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{f_t} + \varepsilon}.$$

该方法忽略参数之间的非对角相关性, 因此应称为“对角经验 Fisher 预条件方法”或“近似自然梯度方法”, 而不是精确自然梯度。

方法	Epoch 1	Epoch 2	Epoch 3
SGD	0.89668 ± 0.00045	0.91188 ± 0.00127	0.91926 ± 0.00123
对角经验 Fisher	0.81120 ± 0.06411	0.90212 ± 0.01605	0.88808 ± 0.05902

表 3: 5 个随机种子下的测试准确率均值与样本标准差。

方法	训练耗时 (秒)
SGD	1.541 ± 0.635
对角经验 Fisher	1.582 ± 0.187

表 4: 训练耗时均值与样本标准差。




图 5: 五个随机种子下 MNIST 测试准确率的均值与误差棒。

从表中可以看到，SGD 与对角经验 Fisher 预条件方法均已训练并进行了比较。在当前超参数下，SGD 在五个随机种子上更稳定，第三轮平均测试准确率为 0.91926 ± 0.00123 ；对角经验 Fisher 方法第三轮平均测试准确率为 0.88808 ± 0.05902 ，标准差较大，说明该近似自然梯度方法对随机初始化和超参数更加敏感。因此，本实验结论不是“近似自然梯度一定优于 SGD”，而是：在该实现和参数设置下，SGD 更稳定；对角经验 Fisher 方法在部分随机种子下可以取得较高准确率，但整体波动更大。

5 第 7 题：强化学习求解迷宫最短路径

首先将原始 RGB 图片划分成规则网格，将可行走区域与墙壁转换为布尔占用矩阵。程序自动检测黄色起点，并选择一个可达终点。智能体可采取上、下、左、右四种动作。

Q-learning 的更新公式为

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right].$$

程序使用 ϵ -greedy 策略平衡探索与利用，并加入 potential-based reward shaping 以加速收敛。BFS 仅用于计算理论最短路径长度，作为结果校验。

指标	数值
迷宫网格大小	(49, 65)
起点	(44, 63)
终点	(8, 45)
BFS 最短路径长度	120
Q-learning 路径长度	120
Q-learning 是否到达终点	True

表 5: 迷宫最短路径实验结果。

由于

$$L_{Q-learning} = 120 = L_{BFS} = 120,$$

Q-learning 不仅找到了可行路线，而且达到了 BFS 给出的理论最短路径长度。




图 6: Q-learning 学习得到的迷宫最短路径。

题目中提到“最好给出交互式界面”。本文主报告展示的是固定终点的可复现实验图；项目中另外提供了交互式脚本 `q7_maze_interactive.py`。运行该脚本后，会弹出迷宫窗口，用户可用鼠标点击任意可达格点作为终点，程序随后训练 Q-learning 策略、输出 BFS 最短路径长度与 Q-learning 路径长度，并在窗口中画出路线。也可以使用命令行方式指定终点，例如：

```
python3 q7_maze_interactive.py --goal 8 45
```

该交互界面作为附加实现，不参与 `run_all.py` 的自动批量运行，以避免批处理时阻塞等待鼠标点击。

6 结论

本文完成了更新过程高阶矩推导、Poisson 神经元群方向解码、音频盲源分离、MNIST 分类和强化学习迷宫寻路五部分内容。第二题的 Monte Carlo 模拟验证了更新计数矩公式；第四题在题目给定的高斯调谐函数下构造 MLE，并验证其接近 Cramér-Rao 下界；第五题中 FastICA 比 PCA 提供了更清晰的源信号分离；第六题比较了 SGD 与对角经验 Fisher 预条件方法；第七题中 Q-learning 获得了与 BFS 相同长度的最短路径。